

Actor-Critic Síncrono (A2C) no CartPole

Gabriel Palhares Siqueira · palhares@discente.ufg.br · Atividade individual · 29/09/2026


Protocolo: 20 treinos no CartPole-v1 (500.000 passos; o controle da Q1 usa 4M) e 13 no LunarLander-v3. Seeds 1 e 2 em toda configuração do CartPole (duas seeds não bastam para conclusões universais: o próprio baseline avalia $360,2 \pm 181,9$ e $500,0 \pm 0,0$; a mesma seed reproduz o treino bit a bit); uma alteração por vez sobre *configs/a2c_cartpole.yml* (8 ambientes, $n = 5$, $\text{ent_coef} = 0,01$, LR $7e-4$, $\gamma = 0,99$). Avaliação final do harness: 10 episódios com a política estocástica (média $\pm$ DP entre episódios). Os 14 testes de *tests/test_a2c.py* passaram. Vídeo desativado; nenhuma outra mudança no harness. **Implementação:** $R(t) = r(t) + \gamma(1 - d(t)) \cdot R(t+1)$, de trás para frente a partir de $R(T) = V(s(T))$, por coluna; perda $-\text{média}(\log \pi(A))$ com $A = R - V(s)$ (ou R) destacado do grafo — constante para o ator, o crítico só aprende pelo *value_loss*; Categorical(logits) com *sample()*/argmax, *log_prob* da ação recebida e *entropy()*.

Fork: github.com/Palharess/t-zero-learning · Gráficos originais: [relatório no W&B](#) (Q1-Q4 e Extra) · Previsões, adições feitas durante a execução e reprodução: [EXPERIMENTOS_A2C.md](#)

Q1 · Número de atores em paralelo (num_envs)

Previsão anterior aos treinos. Com 1 ambiente, cada gradiente usa 5 transições seguidas do mesmo episódio: *policy_loss* muito ruidoso e retorno instável, apesar de $8 \times$ mais atualizações. Com 64, *policy_loss* suave, mas 1.562 atualizações devem atrasar o aprendizado por passo. SPS crescente, mas sublinear.

Varredura. *num_envs* = 1, 8 (baseline) e 64, duas seeds; lotes de 5, 40 e 320. Os seis runs rodaram um de cada vez, sem outro processo, para o SPS ser comparável. Controle adicionado depois: 64 ambientes com 4M passos (as 12.500 atualizações do baseline).



Métricas registradas no W&B, média por blocos de 5.000 passos; cor = configuração, contínua = seed 1, tracejada = seed 2. Curvas sem agregação no link do W&B. 2º painel: x = número de atualizações; pontilhado = controle (s1; s2 em traço-ponto). *policy_loss*: valores brutos da seed 1.

Configuração	Atualiz.	SPS	Tempo (s)	Passos até 450	Atualiz. até 450	DP <i>policy_loss</i>	Avaliação s1	Avaliação s2
1 ambiente	100.000	1.037 / 1.009	485 / 498	— / —	— / —	11,5 / 5,4	$388,8 \pm 137,6$	$500,0 \pm 0,0$
8 (baseline)	12.500	6.201 / 6.266	83 / 83	117k / 148k	2.925 / 3.700	1,6 / 1,6	$360,2 \pm 181,9$	$500,0 \pm 0,0$
64 ambientes	1.562	18.155 / 18.089	32 / 31	— / —	— / —	0,5 / 0,5	$500,0 \pm 0,0$	$172,7 \pm 18,8$
64, 4M (controle)	12.500	—	—	500k / 604k	1.563 / 1.887	0,6 / 0,6	$500,0 \pm 0,0$	$500,0 \pm 0,0$

Explicação. Previsão confirmada. Com 1 ambiente (seed 1), o *policy_loss* fica ≈ 0 em 94% das atualizações e às vezes explode (p99 de $|\text{policy_loss}| = 71$; DP 11,5 e 5,4, contra $\approx 1,6$ no baseline e $\approx 0,5$ com 64). Com recompensa sempre +1, 5 passos seguidos de um episódio quase não trazem sinal (vantagens ≈ 0): o gradiente vem dos raros lotes com fim de episódio, e um único evento decide a direção do passo. O agente segue um estimador de variância enorme — 100.000 passos, cada um ditado por um ou nenhum evento — e o retorno oscila sem chegar a 450. É o argumento do A3C: sem replay, um método on-policy descorrelaciona os dados com vários atores, cujos lotes misturam episódios diferentes da mesma política.

Os dois efeitos se separam no 2º painel. Por atualização, lote maior é melhor: 64 ambientes chegam a 450 com 1.563 e 1.887 atualizações (controle), contra 2.925 e 3.700 do baseline — mas $8 \times$ mais dados por atualização compram só $\sim 2 \times$ menos atualizações. Por passo de ambiente, o baseline vence: em 500 mil passos cabem só 1.562 atualizações com 64 ambientes (retorno final 341 e 148), e o baseline chega a 450 aos 117 mil e 148 mil passos.


O paralelismo compra tempo de relógio: SPS de ≈ 1.000 , 6.200 e 18.100; 500 mil passos em 8,1 min, 83 s e 32 s. O ganho é sublinear ($1 \rightarrow 8$: $6 \times$; $8 \rightarrow 64$: $2,9 \times$) porque o laço principal é serial — uma inferência e uma troca de mensagens com todos os processos por passo — e a máquina tem 12 threads. Em tempo até 450, o baseline foi o melhor (19 e 24 s).

Runs (nome: ID W&B): *num_envs-1-s1*: mvfj1efh; *num_envs-1-s2*: wmqaybi; *baseline-s1*: 9tgtfmsm; *baseline-s2*: 5m832i5l; *num_envs-64-s1*: 29nxdn9j; *num_envs-64-s2*: wvmvuo4y; *num_envs-64-4M-s1*: n75g8t5h; *num_envs-64-4M-s2*: r3qdt4ut.

Q2 · Horizonte do retorno de n passos (a2c.num_steps)

Previsão anterior aos treinos. $n = 1$ (alvo $r + \gamma V(s')$) tem mais viés e menos variância; $n = 128$, quase Monte Carlo, o contrário. Espero *value_loss* crescente com n e *explained_variance* alta, porém enganosa, com $n = 1$; o ator deve sofrer nos extremos.

Varredura. *num_steps* = 1, 5 (baseline), 32 e 128, duas seeds; lotes de 8, 40, 256 e 1.024; 62.500, 12.500, 1.953 e 488 atualizações. Depois do treino, cada crítico final foi comparado com os retornos Monte Carlo da própria política (~ 28 mil transições; *scripts/critic_check_a2c.py*).



Métricas registradas no W&B, retorno: média por blocos de 5.000 passos; value_loss e EV: mediana por blocos de 25.000 (o lote típico); cor = configuração, contínua = seed 1, tracejada = seed 2. Curvas sem agregação no link do W&B. Tabela: $V - \bar{G}$ = viés do crítico final contra retornos Monte Carlo reais da própria política.

Configuração	Atualiz.	Passos até 450	Atualiz. até 450	EV mediana	value_loss médio	$V - \bar{G}$ (MC)	Avaliação s1	Avaliação s2
n = 1	62.500	86k / 191k	10.750 / 23.875	0,95 / 0,66	15 / 22	19,6 / 19,7	500,0 ± 0,0	500,0 ± 0,0
n = 5 (baseline)	12.500	117k / 148k	2.925 / 3.700	0,13 / 0,64	31 / 36	21,5 / 19,2	360,2 ± 181,9	500,0 ± 0,0
n = 32	1.953	359k / —	1.404 / —	0,01 / 0,01	71 / 82	-2,1 / -1,2	500,0 ± 0,0	317,1 ± 57,6
n = 128	488	486k / 475k	475 / 464	0,00 / 0,00	501 / 498	-44,5 / -41,8	432,1 ± 109,3	473,1 ± 40,7

Explicação. n = 1 tem o maior viés — o alvo herda todo o erro de V — e a menor variância (só um passo real entra no alvo). Com n = 128 entram até 128 recompensas reais e o bootstrap pesa $\gamma^{128} \approx 0,28$: pouco viés, mas o instante da queda ou do truncamento muda a soma inteira. No crítico, o value_loss típico cresce ordens de grandeza com n e a EV cai de 0,95 e 0,66 (n = 1) para ≈ 0 (n = 128). Previsão confirmada para o crítico.

A EV de n = 1 parece ótima porque alvo e previsão contêm o mesmo V: $R = 1 + \gamma V(s')$ com $V(s') \approx V(s)$, e qualquer V localmente consistente “explica” o alvo — um V com escala errada ($V = \alpha V^*$) tem erro TD quase constante ($\approx 1 - \alpha$) e EV alta para qualquer α . Contra os retornos reais, o crítico de n = 1 prevê $\bar{V} = 99,9$, o ponto fixo $1/(1 - \gamma)$, para $\bar{G} = 80,3$ (viés de +19,6); o de n = 32 é o mais calibrado (-2,1) e o de n = 128 subestima (-44,5). Com lotes de 8 a EV também é ruidosa, e o value_loss médio é dominado pelos raros lotes com fim de episódio (o harness trata o truncamento em 500 passos como término).


O ator sofre com o crítico porque seu peso é $A = R - V(s)$: com n = 128, $EV \approx 0$ e $advantage_mean \approx +26$ — o baseline não reduz variância e desloca as vantagens para cima, como na Q4. Ainda assim, lotes de 1.024 com alvo quase MC tornam cada atualização muito informativa (450 com 475 e 464 atualizações, contra 2.925 e 3.700 no baseline): faltam atualizações (488), não sinal. A previsão errou para o ator em n = 1, que aprendeu como o baseline (450 aos 86 mil e 191 mil passos, contra 117 mil e 148 mil): o erro de V é quase o mesmo para as duas ações (depende do tempo até o truncamento, que a ação não muda) e só desloca a vantagem.

Runs (nome: ID W&B): num_steps-1-s1: htoykjgw; num_steps-1-s2: 3ob1h9ht; baseline-s1: 9tgtfmsm; baseline-s2: 5m832i5l; num_steps-32-s1: s4817g8a; num_steps-32-s2: kq4gbv5l; num_steps-128-s1: uqs3k08p; num_steps-128-s2: 105ybyqu.

Q3 · Coeficiente de entropia (a2c.ent_coef)

Previsão anterior aos treinos. Sem bônus, entropia caindo mais cedo e mais perto de 0; no CartPole deve funcionar, com risco de uma seed estagnar. Com 0,1, entropia perto de $\ln 2$ e retorno parado abaixo de 500.

Varredura. ent_coef = 0, 0,01 (baseline) e 0,1, duas seeds.



Config.	Entropia final	Retorno final	Avaliação (s1, s2)
ent_coef = 0	0,44 0,47	499 498	457,5 ± 127,5 500,0 ± 0,0
0,01 (baseline)	0,57 0,52	463 490	360,2 ± 181,9 500,0 ± 0,0
ent_coef = 0,1	0,59 0,60	358 344	500,0 ± 0,0 350,3 ± 132,3

Métricas registradas no W&B, média por blocos de 5.000 passos; cor = configuração, contínua = seed 1, tracejada = seed 2. Curvas sem agregação no link do W&B. Pontilhado: $\ln 2$ (política uniforme). Retorno final = média dos últimos 10% do treino.

Explicação. O bônus $-\beta \cdot H$ impede o colapso prematuro: sem ele, um gradiente favorável por acaso torna a softmax determinística, $\nabla \log \pi \rightarrow 0$ e a exploração acaba. Com $\beta = 0,1$ a entropia fica em 0,59 e 0,60 do início ao fim e o retorno estaciona em 358 e 344 (máx. 379 e 363): o ótimo do objetivo regularizado é $\pi(a|s) \propto \exp(A(s,a)/\beta)$, e onde a diferença de vantagem entre as ações é comparável a β a ação errada mantém probabilidade relevante — em 500 passos alguma dessas escolhas derruba a haste. Confirmado.


Sem bônus, as duas seeds funcionaram (retorno final 498,8 e 498,1, o melhor da varredura) e a entropia caiu menos do que previ (0,44 e 0,47 contra 0,57 e 0,52), sem colapsar. O CartPole é benevolente: recompensa densa, duas ações, política inicial quase uniforme e falhas rápidas que dão sinal em todo episódio; como na maioria dos estados as ações são quase equivalentes (vantagens ≈ 0), o gradiente só a torna determinística onde importa. Com mais ações ou recompensa rara, a política pode se fixar na primeira ação com vantagem positiva por acaso antes de achar a recompensa, e sem entropia nada a tira de lá (ver o Extra).

Runs (nome: ID W&B): ent_coef-0-s1: gk623oe2; ent_coef-0-s2: ltn9xiod; baseline-s1: 9tgtfmsm; baseline-s2: 5m832i5l; ent_coef-0.1-s1: gww6kmwn; ent_coef-0.1-s2: hly4izgd.

Q4 · Ablação do baseline (a2c.use_baseline = false)

Previsão anterior aos treinos. Sem baseline o peso é R, sempre positivo (dezenas): $advantage_mean \gg 0$ e $advantage_std$ várias vezes maior; como todo peso é positivo, a entropia deve colapsar mais cedo e o retorno ficar mais lento e instável, embora o gradiente esperado seja o mesmo.

Varredura. use_baseline = true (baseline) e false, duas seeds.



Convenções como na Q1 (média por blocos de 5.000 passos; contínua = seed 1, tracejada = seed 2).

Configuração	advantage_mean (média)	advantage_std (mediana)	grad_norm (mediana)	Entropia final	Entropia < 0,1 em	Retorno final	Avaliação s1	Avaliação s2
com baseline	-0,4 / -0,5	0,02 / 0,02	0,06 / 0,06	0,566 / 0,515	— / —	463 / 490	360,2 ± 181,9	500,0 ± 0,0
sem baseline	51,3 / 71,7	15,83 / 8,86	19,6 / 31,5	0,003 / 0,004	86k / 107k	138 / 243	136,2 ± 24,2	361,6 ± 111,4

Explicação. Subtrair $b(s)$ não muda o gradiente esperado — a média de $\nabla \log \pi(a|s)$ sob $a \sim \pi \equiv \nabla \Sigma \pi(a|s) = \nabla 1 = 0$ —, mas muda o segundo momento dos pesos: com baseline, média -0,4 e -0,5 e desvio mediano 0,02 e 0,02; sem, média +51 e 72 e desvio mediano 15,8 e 8,9. A norma do gradiente (mediana) sobe de 0,06 e 0,06 para 20 e 32, e 100 e 99% dos passos são cortados pelo clipping (0,5), contra 27 e 30% com baseline: a direção passa a ser dominada pelo termo comum a todas as amostras. Confirmado.


Com $R > 0$ sempre, todo passo aumenta $\log \pi$ da ação amostrada, seja ela boa ou ruim; a informação útil está só na variação de R em torno da média, pequena perto dela. A ação mais provável é amostrada — e reforçada — mais vezes, um ciclo que torna a política determinística: entropia < 0,1 aos 86 mil e 107 mil passos e 0,003 e 0,004 no fim (baseline: 0,57 e 0,52); o bônus de 0,01 é irrelevante diante de pesos ~ 50 . Sem exploração não há correção: a seed 2 chegou a 500 e caiu para 243; a seed 1 chegou a 330 e terminou em 138.

Runs (nome: ID W&B): baseline-s1: 9tgftmsm; baseline-s2: 5m832i5l; no_baseline-s1: w83ikp4q; no_baseline-s2: 1yzysd7d.

Extra · LunarLander-v3

Previsão anterior aos treinos. Com a config do CartPole e 500 mil passos, não deve resolver: recompensas de -100/+100 no fim de episódios de até 1.000 passos exigem mais passos, retornos mais longos e entropia menor no fim. Espero `value_loss` muito maior que no CartPole e `explained_variance` baixa no início.

Varredura. Uma seed a partir da config do CartPole (500 mil e 3M passos; 16 amb. $\times n = 16$; $\gamma = 0,995$; $\gamma = 0,995$ e $0,999$ com `ent_coef = 0,001`); depois, duas seeds para a melhor delas e para três correções com 5M passos (LR $2,5e-4$ com $\gamma = 0,999$ e $0,995$; 64 ambientes).



Média por blocos de 25.000 passos (EV: mediana); pontilhados: 200 (resolvido), 1.000 passos (truncamento) e $\ln 4$. “+”: sobre γ e `ent_coef` = 0,001, com 16 ambientes (LR) ou LR $7e-4$ (64 amb.). Tabela: valores finais = últimos 10% do treino (s1 / s2).

Configuração	Passos	Máx. (100 ep.)	Retorno final	Duração final	EV mediana	Avaliação s1	Avaliação s2
γ 0,995, <code>ent_coef</code> 0,001	3,0M	225 / 195	172 / 143	265 / 380	0,99 / 0,99	227,6 ± 66,0	178,1 ± 116,6
γ 0,999, <code>ent_coef</code> 0,001	3,0M	203	-26	593	0,98	-103,2 ± 22,5	—
γ 0,999 + LR $2,5e-4$	5,0M	197 / 206	89 / 1	489 / 788	0,97 / 0,97	52,1 ± 126,3	78,4 ± 124,3
γ 0,999 + 64 amb.	5,0M	172 / 177	-142 / -112	515 / 394	0,87 / 0,91	-143,3 ± 37,5	-112,0 ± 53,7
γ 0,995 + LR $2,5e-4$	5,0M	79 / 110	-145 / -119	428 / 430	0,95 / 0,96	-151,0 ± 36,0	-149,1 ± 48,9

Explicação. Previsão certa quanto ao orçamento e errada quanto ao crítico. A config do CartPole aprende a não cair (de -200 a $\sim +75$ em 400 mil passos) e passa a pairar: episódios de 779 passos, retorno final 30 (com 3M: máx. 140, final -47; avaliação $26,3 \pm 129,4$). Em relação ao CartPole: (i) o bônus de pouso (+100) vem centenas de passos depois e cada passo com motor custa, então γ maior valoriza pousar (a 200 passos, $0,99^{200} \approx 13\%$ e $0,995^{200} \approx 37\%$); (ii) com 4 ações e pouso preciso, `ent_coef` = 0,01 mantém a entropia em $\sim 0,6$ e aciona motores ao acaso — $\gamma = 0,995$ sozinho chegou a 147, e com `ent_coef` = 0,001 a 225; (iii) são precisos 3-5M passos. O crítico não é o gargalo: a EV passa de 0,9 cedo, pois a recompensa de modelagem torna V previsível pelo estado (no CartPole, o tempo até o truncamento é invisível).

O limite é o ator. Todas as variantes oscilam: sobem (máx. de 79 a 225) e recaem primeiro no ótimo local de pairar — a duração salta para ~ 900 -1.000 passos (truncamento) — e, em alguns runs, depois para voos que terminam em queda (retorno final de -110 a -150). Nem passos menores (LR $2,5e-4$: final 89 e 1 com $\gamma = 0,999$; -145 e -119 com $\gamma = 0,995$) nem lotes maiores (64 amb.: -142 e -112) evitaram a recaída. O A2C não limita quanto a política muda por atualização (não há região de confiança, como no PPO) e é on-policy: pairando, o agente quase não vê pousos e perde o sinal que o traria de volta; um `ent_coef` maior ajudaria a sair dali, mas atrapalha a precisão do pouso. Cheguei perto sem resolver: $\gamma = 0,995$ com `ent_coef` = 0,001 passou de 200 na seed 1 (máx. 225; avaliação $227,6 \pm 66,0$) e chegou a 195 na seed 2 (avaliação $178,1 \pm 116,6$).

Runs (nome: ID W&B): cartpole_cfg-s1: xs7850zg; cartpole_cfg-3M-s1: epwcu2q4; e16n16-3M-s1: 4kjjkwod; g995-3M-s1: tf5wliut; g995-ent001-3M-s1: en8tg67w; g995-ent001-3M-s2: 4zy17470; g999-ent001-3M-s1: im3e8523; g999-lr25-e16-5M-s1: 8sf8qgn; g999-lr25-e16-5M-s2: 4pr7wsgb; g999-e64-5M-s1: 9pn2a7k3; g999-e64-5M-s2: piaeh97b; g995-lr25-e16-5M-s1: zjnl9fyf; g995-lr25-e16-5M-s2: oen4hqnz.