

Deep Q-Networks no CartPole

Gabriel Palhares Siqueira · Atividade individual · 21/09/2026


Protocolo: 14 treinos de 500.000 passos; seeds 1 e 2; uma alteração por vez. Baseline: frequência 500, buffer 10.000, LR 0,00025, $\gamma = 0,99$; demais parâmetros originais. Avaliação greedy: 10 episódios. Os 7 testes de DQN passaram. Vídeos desativados; sem mudança no algoritmo de treino.

Fork: github.com/Palharess/t-zero-learning · Gráficos originais: relatório público no W&B (Q1, Q2 e Q3).

Q1 · Frequência da target network

Previsão anterior aos treinos. Sincronizar a cada passo deve aumentar o acoplamento do bootstrap e a instabilidade de Q e retorno. Um alvo atualizado a cada 10.000 passos deve variar menos, mas propagar os valores mais lentamente.

Varredura. Frequências 1, 500 (baseline) e 10.000; duas seeds por valor. Reporto retorno, TD loss e Q médio para distinguir desempenho, ajuste ao alvo e escala dos valores.



Curvas das métricas registradas no W&B; média por blocos de 5.000 passos para legibilidade. Cada cor é uma configuração; linha contínua = seed 1, tracejada = seed 2. Erro TD em escala symlog. As curvas originais sem essa agregação estão no link do W&B.

Configuração	Greedy s1: média ± DP	Greedy s2: média ± DP
Frequência 1	500,0 ± 0,0	500,0 ± 0,0
Frequência 500	500,0 ± 0,0	500,0 ± 0,0
Frequência 10.000	229,0 ± 41,6	287,1 ± 54,7

Explicação. A previsão de instabilidade com frequência 1 se confirmou durante o treino, mas não como perda final: ambas as seeds avaliaram em 500. O gráfico de Q apresenta picos brutos de 1.472 e 1.129, muito acima do limite de retorno descontado $1/(1-0,99) = 100$, pois a recompensa por passo é 1. O bootstrap com máximo reutiliza estimativas superestimadas e o alvo acompanha a rede online, favorecendo realimentação; o gráfico de retorno mostra oscilações e recuperação. A sincronização periódica reduz esse acoplamento.


Com frequência 10.000, Q termina em apenas 36,6 e 37,4, e o retorno fica abaixo do baseline, confirmando a previsão de aprendizado mais lento. O TD loss final é só 0,0067 e 0,048: a rede ajustou bem um alvo ainda defasado. A loss mede erro no minibatch contra esse alvo, não a qualidade da política nem o erro contra o Q verdadeiro; por isso pode parecer boa mesmo quando o retorno é baixo ou degradado.

Runs (nome: ID): target-1-s1: 72f7ox7e; target-1-s2: kmjxhw6y; baseline-s1: tgh6drnn; baseline-s2: x9oofvwr; target-10000-s1: 5mej345; target-10000-s2: 8ivfad3e.

Q2 · Tamanho do replay buffer

Previsão anterior aos treinos. Um buffer de 128 deve reduzir a diversidade e esquecer rapidamente experiências antigas, causando instabilidade. Um buffer de 100.000 preserva mais situações, mas pode retardar a adaptação por conservar dados de políticas antigas.

Varredura. Capacidades 128, 10.000 (baseline) e 100.000; duas seeds por valor. Reporto retorno e Q para observar o efeito na política e nas estimativas, mantendo batch size 128.



Curvas das métricas registradas no W&B; média por blocos de 5.000 passos para legibilidade. Cada cor é uma configuração; linha contínua = seed 1, tracejada = seed 2. As curvas originais sem essa agregação estão no link do W&B.

Configuração	Greedy s1: média ± DP	Greedy s2: média ± DP
Buffer 128	500,0 ± 0,0	270,5 ± 5,5
Buffer 10.000	500,0 ± 0,0	500,0 ± 0,0
Buffer 100.000	500,0 ± 0,0	500,0 ± 0,0

Explicação. O gráfico de retorno do buffer 128 mostra forte instabilidade na seed 2: após chegar perto de 500, cai quase a 40 por volta de 310 mil passos, recupera e volta a cair no fim. A avaliação termina em 270,5, contra 500 na seed 1. O gráfico de Q também oscila e termina em 61,0 versus 115,3. A previsão de fragilidade se confirmou, sem significar que todo treino com buffer pequeno fracassa.


Há dois mecanismos distintos. Primeiro, as transições disponíveis vêm de uma janela temporal curta: estados próximos e repetições com reposição tornam o minibatch pouco diverso, mesmo com índices uniformes. Segundo, o FIFO elimina rapidamente experiências de episódios e políticas anteriores; a rede deixa de rever situações já aprendidas e pode esquecer como agir nelas. O buffer 100.000 conserva essas experiências, mas não foi melhor que o baseline: a curva de retorno sobe mais devagar e Q atinge picos próximos de 400, contra cerca de 230 no baseline. Isso é compatível com a maior presença de dados antigos e mostra que buffer grande não elimina superestimação; apesar disso, ambas as avaliações finais atingem 500.

Runs (nome: ID): buffer-128-s1: 85kbwytd; buffer-128-s2: 1vb06vsh; baseline-s1: tgh6drnn; baseline-s2: x9oofvwr; buffer-100000-s1: v4zrpizp; buffer-100000-s2: h9qsors5.

Q3 · Taxa de aprendizado (extra)

Previsão anterior aos treinos. Uma taxa dez vezes menor deve reduzir a magnitude das atualizações, mas aprender mais devagar. Uma taxa dez vezes maior pode gerar picos de TD loss e instabilidade de Q, prejudicando o retorno.

Varredura. Taxas 0,000025, 0,00025 (baseline) e 0,0025; duas seeds por valor. Escolhi retorno para medir desempenho, TD loss para acompanhar o ajuste e Q para detectar superestimação; juntos distinguem lentidão e instabilidade.



Curvas das métricas registradas no W&B; média por blocos de 5.000 passos para legibilidade. Cada cor é uma configuração; linha contínua = seed 1, tracejada = seed 2. Erro TD em escala symlog. As curvas originais sem essa agregação estão no link do W&B.

Configuração	Greedy s1: média ± DP	Greedy s2: média ± DP
LR 0,000025	182,4 ± 12,0	158,6 ± 13,0
LR 0,00025	500,0 ± 0,0	500,0 ± 0,0
LR 0,0025	500,0 ± 0,0	125,5 ± 4,5

Explicação. A taxa 0,000025 termina com retorno greedy de 182,4 e 158,6, abaixo de 500 no baseline, confirmando a previsão de aprendizado lento no orçamento fixo. O gráfico de Q mostra valores finais de 71,5 e 53,6, e o retorno ainda oscila: passos menores do otimizador não garantem uma política estável. Como o alvo também muda, a rede pode continuar mal ajustada mesmo com atualizações pequenas.

Com taxa 0,0025, o gráfico de Q revela superestimação mais forte: picos brutos de cerca de 377 e 564, contra 227 e 237 no baseline. O gráfico de TD loss também mostra picos maiores, e a curva de retorno apresenta quedas após melhora. Atualizações grandes alteram rapidamente os valores, que alimentam os próximos alvos de bootstrap; o erro pode ser amplificado. A avaliação final foi 500 na seed 1 e 125,5 na seed 2: a previsão de instabilidade se confirmou, e o prejuízo final ocorreu em uma das duas execuções. Q superestimado pode coexistir com retorno 500, pois a política depende da ordem das ações, não da escala absoluta. As três curvas e a avaliação final são necessárias para interpretar o resultado.

Runs (nome: ID): lr-small-s1: ag28lojg; lr-small-s2: soautcy3; baseline-s1: tgh6drnn; baseline-s2: x9oofvwr; lr-large-s1: k2djyn33; lr-large-s2: dxd8na8m.

Limites: duas seeds não permitem conclusões universais. DP acima é entre os 10 episódios da mesma avaliação, não entre seeds. O harness original não fixa a seed do sorteio de ações exploratórias nem do reset da avaliação; a repetição exata das curvas não é garantida. Previsões, versões e scripts de reprodução estão no fork.